UNICAMP

MC 906

PROJETO 2 - PORTIFÓLIO

Pedro Henrique dos Reis Arcoverde-254719

Professor: Anderson

Cidade
3 de maio de 2026

Resumo

Este é o resumo do relatório. Aqui você descreve brevemente o objetivo, metodologia e resultados.

Sumário

1 Introdução **2**

2 Fundamentação Teórica **2**

2.1 Subseção Exemplo 2

3 Metodologia **2**

4 Experimentos **2**

4.1 Implementação das Equações de Bellman 2

4.2 Análise de Resultados: Value Iteration 2

4.3 Discussão Técnica 3

4.4 Análise Experimental: Q-Learning 3

4.4.1 Correção do Comportamento Anômalo (Ações Inválidas) 3

4.4.2 Evolução da Curva de Aprendizado e Exploração 4

4.4.3 Política Ótima Aprendida e Perfil de Risco 4

5 Conclusão **4**

1 Introdução

Apresente o tema do relatório, contexto e objetivos.

2 Fundamentação Teórica

Explique os conceitos teóricos relevantes.

2.1 Subseção Exemplo

Detalhamento de algum tópico específico.

3 Metodologia

Descreva como o trabalho foi realizado.

4 Experimentos

Para esta seção vamos começar a olhar para uma implementação real dos nosso modelos de inteligência artificial: Bellman e Q-Learning destrinchando as suas composições e alterando os valores das variáveis que regem o comportamento dois dois de forma a tentar extrair o máximo de informção sobre o funcionamento, estratégia e rendimentos no fluxo de decisão.

4.1 Implementação das Equações de Bellman

Utilizou-se o algoritmo de *Value Iteration* para determinar a política ótima através da atualização iterativa dos valores de estado $V(s)$:

$$V(s) \leftarrow \max_a \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma V(s')]$$

O experimento foi configurado com um fator de desconto $\gamma = 0.99$ e um critério de convergência $\theta = 1e-5$.

4.2 Análise de Resultados: Value Iteration

O algoritmo convergiu após **1.796 iterações**. Os resultados detalhados encontram-se na Tabela 1.

Tabela 1: Valores de Estado ($V(s)$) e Política Aprendida

Estado	**Valor** $V(s)$	**Ação Ótima**
0 (DOWN, CASH)	1,38E+09	BUY
1 (DOWN, HOLDING)	1,41E+09	HOLD
2 (FLAT, CASH)	1,34E+09	SELL*
3 (FLAT, HOLDING)	1,36E+09	HOLD
4 (UP, CASH)	1,33E+09	BUY
5 (UP, HOLDING)	1,32E+09	SELL

4.3 Discussão Técnica

Observou-se uma magnitude extremamente elevada nos valores da *V-Table* (na ordem de 10^9). Este fenômeno é decorrente da combinação de um horizonte de planejamento longo com um fator de desconto γ muito próximo da unidade em um ambiente com tendência de crescimento (*drift*) positiva.

Análise Crítica: A política ótima no Estado 2 indicou a ação de venda mesmo sem a posse do ativo (*CASH*). Tecnicamente, a recompensa esperada a longo prazo tornou-se tão vasta que a penalidade estática por ação inválida ($r = -1.0$) tornou-se insignificante no cálculo do valor esperado. Para mitigar este comportamento e garantir a estabilidade da política, recomenda-se a normalização das recompensas ou a aplicação de penalidades proporcionais ao patrimônio líquido.

4.4 Análise Experimental: Q-Learning

Para avaliar o aprendizado *model-free* e mitigar as a nomalias observadas no planejamento de Bellman, foi conduzida uma busca em grade (*Grid Search*) com o algoritmo Q-Learning. A análise a seguir foca na configuração de melhor interpretabilidade e estabilidade, obtida com taxa de aprendizado $\alpha = 0.1$ e fator de desconto $\gamma = 0.9$.

4.4.1 Correção do Comportamento Anômalo (Ações Inválidas)

No algoritmo de *Value Iteration*, a combinação de horizonte infinito e tendência positiva (*drift*) ofuscou a penalidade estática do ambiente ($r = -1.0$), levando o agente a tentar vender ativos que não possuía. O Q-Learning corrigiu este comportamento com sucesso.

A inspeção da Tabela Q final revela que os valores esperados para ações inválidas convergiram quase perfeitamente para a magnitude da penalidade configurada. Por exemplo, no Estado 0 (*DOWN, CASH*), o valor da ação *SELL* atingiu $Q(s_0, a_2) \approx -0.966$. O mesmo ocorreu nos Estados 2 e 4. Isso comprova empíricamente que o agente aprendeu as restrições físicas do MDP interagindo com o ambiente, evitando ações punitivas.

4.4.2 Evolução da Curva de Aprendizado e Exploração

O histórico de recompensas reflete a transição direta da fase de exploração para a de explotação, controlada pelo decaimento da política ϵ-greedy (de $\epsilon = 1.0$ até $\epsilon_{min} = 0.05$).

- **Fase Inicial (Alta Exploração):** Nos primeiros 50 episódios, o agente obteve recompensas altamente negativas (entre -30 e -45). Este déficit não provém primariamente de perdas de mercado, mas sim de multas operacionais frequentes devido à aleatoriedade das ações (tentativas contínuas de ações inválidas).
- **Convergência (Alta Explotação):** Conforme ϵ decai para 0.05, a hemorragia de capital cessa. As recompensas nos últimos 100 episódios estabilizam-se em torno de 0.0, demonstrando que o algoritmo aprendeu a interromper os erros operacionais e a preservar o patrimônio líquido.

4.4.3 Política Ótima Aprendida e Perfil de Risco

A extração da política ótima ($\arg\max_a Q(s, a)$) revelou o desenvolvimento de um agente com um perfil estritamente conservador e de alta aversão ao risco. A Tabela 2 detalha as decisões aprendidas.

Tabela 2: Política de Investimento Aprendida (Q-Learning: $\alpha = 0.1, \gamma = 0.9$)

Estado do Mercado	**Ação Ótima**	**Interpretação Financeira**
0 (DOWN, CASH)	HOLD	Preservação de capital em mercado de baixa.
1 (DOWN, HOLDING)	SELL	Acionamento de *Stop-Loss* para estancar perdas.
2 (FLAT, CASH)	HOLD	Aguarda sinal claro de tendência.
3 (FLAT, HOLDING)	HOLD	Mantém posição em consolidação.
4 (UP, CASH)	HOLD	Evita falsos rompimentos (aversão ao risco).
5 (UP, HOLDING)	SELL	Realização de lucros (*Take Profit*).

Discussão Técnica: O comportamento mais contraintuitivo ocorre no Estado 4, onde o agente em caixa decide não comprar durante uma tendência de alta. Sob a ótica do Aprendizado por Reforço, isso é justificado pelo baixo α (0.1) em um ambiente sintético com ruído estocástico considerável. O agente foi punido sucessivamente por falsos sinais de alta durante o treinamento. Consequentemente, o modelo concluiu que a volatilidade inerente da compra supera o retorno seguro e garantido de manter o capital em caixa (que não sofre decaimento). O modelo priorizou, com sucesso, a sobrevivência ao invés da especulação agressiva.

5 Conclusão

Resumo final e possíveis trabalhos futuros.