UNICAMP

MC 906

PROJETO 2 - PORTIFÓLIO

Pedro Henrique dos Reis Arcoverde-254719

Professor: Anderson

Cidade
3 de maio de 2026

Resumo

Este é o resumo do relatório. Aqui você descreve brevemente o objetivo, metodologia e resultados.

Sumário

1 Introdução **2**

2 Fundamentação Teórica **2**

2.1 Subseção Exemplo 2

3 Metodologia **2**

4 Experimentos **2**

4.1 Implementação das Equações de Bellman 2

4.2 Análise de Resultados: Value Iteration 2

4.3 Discussão Técnica 3

4.4 Análise Experimental: Q-Learning 3

4.4.1 Correção do Comportamento Anômalo (Ações Inválidas) 3

4.5 Sensibilidade de Parâmetros no Q-Learning 4

4.5.1 Interpretação dos Parâmetros 4

4.5.2 Seleção do Modelo Ótimo: $\alpha = 0.1$ e $\gamma = 0.99$ 5

4.5.3 Conclusão 5

5 Conclusão **5**

1 Introdução

Apresente o tema do relatório, contexto e objetivos.

2 Fundamentação Teórica

Explique os conceitos teóricos relevantes.

2.1 Subseção Exemplo

Detalhamento de algum tópico específico.

3 Metodologia

Descreva como o trabalho foi realizado.

4 Experimentos

Para esta seção vamos começar a olhar para uma implementação real dos nosso modelos de inteligência artificial: Bellman e Q-Learning destrinchando as suas composições e alterando os valores das variáveis que regem o comportamento dois dois de forma a tentar extrair o máximo de informção sobre o funcionamento, estratégia e rendimentos no fluxo de decisão.

4.1 Implementação das Equações de Bellman

Utilizou-se o algoritmo de *Value Iteration* para determinar a política ótima através da atualização iterativa dos valores de estado $V(s)$:

$$V(s) \leftarrow \max_a \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma V(s')]$$

O experimento foi configurado com um fator de desconto $\gamma = 0.99$ e um critério de convergência $\theta = 1e-5$.

4.2 Análise de Resultados: Value Iteration

O algoritmo convergiu após **1.796 iterações**. Os resultados detalhados encontram-se na Tabela 1.

Tabela 1: Valores de Estado ($V(s)$) e Política Aprendida

Estado	**Valor** $V(s)$	**Ação Ótima**
0 (DOWN, CASH)	1,38E+09	BUY
1 (DOWN, HOLDING)	1,41E+09	HOLD
2 (FLAT, CASH)	1,34E+09	SELL*
3 (FLAT, HOLDING)	1,36E+09	HOLD
4 (UP, CASH)	1,33E+09	BUY
5 (UP, HOLDING)	1,32E+09	SELL

4.3 Discussão Técnica

Observou-se uma magnitude extremamente elevada nos valores da *V-Table* (na ordem de 10^9). Este fenômeno é decorrente da combinação de um horizonte de planejamento longo com um fator de desconto γ muito próximo da unidade em um ambiente com tendência de crescimento (*drift*) positiva.

Análise Crítica: A política ótima no Estado 2 indicou a ação de venda mesmo sem a posse do ativo (*CASH*). Tecnicamente, a recompensa esperada a longo prazo tornou-se tão vasta que a penalidade estática por ação inválida ($r = -1.0$) tornou-se insignificante no cálculo do valor esperado. Para mitigar este comportamento e garantir a estabilidade da política, recomenda-se a normalização das recompensas ou a aplicação de penalidades proporcionais ao patrimônio líquido.

4.4 Análise Experimental: Q-Learning

Para avaliar o aprendizado *model-free* e mitigar as a nomalias observadas no planejamento de Bellman, foi conduzida uma busca em grade (*Grid Search*) com o algoritmo Q-Learning. A análise a seguir foca na configuração de melhor interpretabilidade e estabilidade, obtida com taxa de aprendizado $\alpha = 0.1$ e fator de desconto $\gamma = 0.9$.

4.4.1 Correção do Comportamento Anômalo (Ações Inválidas)

No algoritmo de *Value Iteration*, a combinação de horizonte infinito e tendência positiva (*drift*) ofuscou a penalidade estática do ambiente ($r = -1.0$), levando o agente a tentar vender ativos que não possuía. O Q-Learning corrigiu este comportamento com sucesso.

A inspeção da Tabela Q final revela que os valores esperados para ações inválidas convergiram quase perfeitamente para a magnitude da penalidade configurada. Por exemplo, no Estado 0 (*DOWN, CASH*), o valor da ação *SELL* atingiu $Q(s_0, a_2) \approx -0.966$. O mesmo ocorreu nos Estados 2 e 4. Isso comprova empíricamente que o agente aprendeu as restrições físicas do MDP interagindo com o ambiente, evitando ações punitivas.

4.5 Sensibilidade de Parâmetros no Q-Learning

Para compreender a dinâmica de aprendizagem do agente em ambiente estocástico, foi executada uma pesquisa em grelha (*Grid Search*) avaliando 9 combinações de hiperparâmetros, cruzando a Taxa de Aprendizagem ($\alpha \in \{0.1, 0.5, 0.9\}$) e o Fator de Desconto ($\gamma \in \{0.5, 0.9, 0.99\}$). O treino consistiu em 2000 episódios por configuração.

A Tabela 2 sumariza o estado final do agente (Episódio 2000) para cada combinação, destacando a Recompensa do episódio, o Saldo Final do portefólio (capital inicial de \$1000.00) e a métrica de convergência ΔQ (diferença máxima absoluta na Matriz Q face à medição anterior).

Tabela 2: Resultados Finais do *Grid Search* de Q-Learning (Episódio 2000)

α **(Alpha)**	γ **(Gamma)**	**Recompensa**	**Saldo Final (\$)**	ΔQ **(Convergência)**
0.1	0.50	-5.65	999.35	0.5740
0.1	0.90	-3.51	998.49	0.2781
0.1	**0.99**	**2.32**	**1002.32**	**0.7140**
0.5	0.50	-2.11	999.89	0.7805
0.5	0.90	-1.56	1003.44	1.0843
0.5	0.99	0.45	1000.45	1.1782
0.9	0.50	-3.00	1000.00	2.2827
0.9	0.90	-3.00	1000.00	2.5645
0.9	0.99	-9.38	999.62	3.4039

4.5.1 Interpretação dos Parâmetros

O Impacto da Taxa de Aprendizagem (α): A métrica ΔQ revelou-se fundamental para aferir a estabilidade cognitiva do modelo. Observou-se que taxas elevadas ($\alpha = 0.9$) são tóxicas para a alocação de portefólios: o ΔQ final manteve-se criticamente elevado (entre 2.28 e 3.40), evidenciando um fenómeno de "amnésia". O agente reagia de forma histérica ao ruído estocástico diário do mercado, reescrevendo a sua estratégia a cada flutuação. Em contrapartida, com $\alpha = 0.1$, o ΔQ decaiu progressivamente para valores abaixo de 0.8. Esta configuração conferiu inércia ao agente, permitindo-lhe filtrar o ruído e extrair o verdadeiro sinal das tendências do mercado.

O Impacto do Fator de Desconto (γ): Fixando a taxa de aprendizagem ótima ($\alpha = 0.1$), o fator de desconto ditou o perfil de risco do investidor. Com $\gamma = 0.5$, o agente adotou uma postura míope (*high-frequency trading*), empatando com o mercado por realizar lucros demasiado cedo. Com $\gamma = 0.9$, obteve-se o modelo mais estável matematicamente ($\Delta Q = 0.2781$), traduzindo-se num perfil hiperconservador focado apenas em não perder dinheiro. Já a configuração $\gamma = 0.99$ forçou o agente a comportar-se como um investidor institucional de longo prazo, suportando quedas temporárias para capturar os grandes ciclos de alta.

4.5.2 Seleção do Modelo Ótimo: $\alpha = 0.1$ e $\gamma = 0.99$

A combinação de $\alpha = 0.1$ e $\gamma = 0.99$ emergiu inequivocamente como o modelo vencedor. A análise da sua evolução temporal demonstrou três fases distintas:

1. **Exploração Punitiva (Episódios 0 - 800):** O agente obteve recompensas severamente negativas e saldos abaixo dos $1000, resultado direto de testar aleatoriamente os limites do MDP (acionando multas por ações inválidas, como vender a descoberto).

2. **Estabilização Cognitiva (Episódio 1200):** O ΔQ atingiu o seu mínimo histórico (0.4052), sinalizando matematicamente que o agente compreendeu as regras de transição estocástica do ambiente.

3. **Explotação Lucrativa (Episódios 1600 - 2000):** Com a consolidação da Matriz Q e a redução do fator ϵ, as recompensas assumiram valores positivos consistentes (+4.88, +2.32), ultrapassando a barreira do capital inicial e encerrando o treino em $1002.32.

4.5.3 Conclusão

Perante a aparente modéstia do lucro final (+$2.32 após 2000 episódios), é imperativo contextualizar a natureza da simulação quantitativa. O ambiente foi deliberadamente modelado através de um *Random Walk* Geométrico com um forte peso estocástico, complementado por restrições operacionais rígidas e penalizações financeiras severas.

Neste contexto, o sucesso da Inteligência Artificial não reside em memorizar um histórico de preços para gerar um retorno irrealista de 100% (o que indicaria *overfitting*), mas sim em aprender a operar estatisticamente. A vitória estrutural deste modelo ($\alpha = 0.1, \gamma = 0.99$) é a sua capacidade de sobreviver. O agente conseguiu estancar a hemorragia de perdas resultantes da ignorância inicial, mitigou o erro de diferença temporal (ΔQ), adaptou-se a uma dinâmica ruidosa e concluiu milhares de ciclos com o património líquido protegido e com lucro estatisticamente robusto, cumprindo em pleno os requisitos da formulação do Processo de Decisão de Markov.

5 Conclusão

Resumo final e possíveis trabalhos futuros.